ZenFeed AI

Autonomní agent pro kontextovou filtraci obsahu, de-eskalaci tónu a boj proti informačnímu přehlcení

Autoři: Jakub Procházka (xproch40), Libuše Babičková

1. Cíl a vize projektu

Cílem projektu je vytvořit inteligentní Chrome extension, které uživateli vrací kontrolu nad jeho digitálním prostorem. **ZenFeed AI** řeší dva hlavní problémy:

1. **Nadbytečné informace:** zpravodajské články s tématy, které uživatele nezajímají nebo je záměrně nechce číst, či např. příspěvky na sociálních sítí od lidí, které uživatel nesleduje.
2. **Toxicitu:** Tlak negativních emocí, katastrofických scénářů, politických konfliktů a zpráv o úmrtí.

Systém funguje jako univerzální DOM mutátor, který se přizpůsobuje typu navštívené stránky a umožňuje uživateli definovat vlastní pravidla filtrování.

2. Klíčové funkce a inovativní prvky

- **Kontextové přizpůsobení podle typu webu:**
  - Rozšíření pomocí **URL patternů a analýzy DOM struktury** automaticky rozpozná, zda uživatel brouzdá na zpravodajském portálu, nebo na sociální síti
  - **AI doporučení filtrů:** Po aktivaci na novém webu AI sama navrhne, co by se dalo skrývat nebo upravovat (např. na sociálních sítích detekuje doporučený feed od nesledovaných tvůrců a nabídne jeho skrytí; na zpravodajství nabídne filtrování konkrétních témat).
- **Filtrování citlivých témat a emocí:**
  - Uživatel si může zvolit, jaká témata u něj vyvolávají úzkost. To jsou například *politika, válka, krizové události, smrt*. Systém tyto články nebo bloky příspěvků skryje nebo nahradí minimalistickým boxem.
- **Mírnější přístup:**
  - U zpravodajských webů lze aktivovat režim „Mírnější přístup“. AI namísto děsivých, křičících titulků a citově vydírajících textů přeformátuje obsah do věcných, klidných faktů a **ke každému článku automaticky přidá stručné shrnutí (TL;DR box)**.
- **Sociální sítě:**

- U sociálních sítí, jako jsou Twitter nebo Instagram, se v poslední době rozšířil trend doporučování obsahu od ostatních lidí. Tento obsah však může být zkreslující, protože vytváří iluzi úspěchu ostatních nebo vyvolává nepříjemné pocity. Proto by se rozšíření zaměřovalo výhradně na obsah, který uživatel sám sleduje.

3. Jak systém pozná, kde se nachází?

Aby rozšíření vědělo, jak se na daném webu chovat, využívá **URL Routing a Content Structure Analysis**:

- **Whitelisting & URL Patterns:** Rozšíření registruje pravidla pro domény (např. instagram.com, twitter.com, seznamzpravy.cz).
- **DOM Signatures (Injekce skriptu):** Content script po načtení stránky detekuje specifické HTML značky nebo CSS selektory. Pokud narazí na neznámou „random" stránku, pošle její strukturu na backend, kde AI vyhodnotí: *„Tento web vypadá jako zpravodajský portál, doporučuji uživateli nabídnout blokaci politiky a mírnější tón."*

4. Použité AI technologie a koncepty

Projekt v sobě kombinuje širokou škálu moderních metod umělé inteligence:

1. **Structured Outputs (Constrained Generation přes Pydantic):**
   a. Backend vrací přesný JSON formát, který říká frontendu (rozšíření), které konkrétní HTML elementy se mají smazat, přepsat, nebo kam se má vložit box se shrnutím.
2. **Text Classification & Zero-shot Topic Detection:**
   a. Klasifikace článků a příspěvků do tematických kategorií (politika, válka, zábava, sport) a detekce toxicity/negativity za účelem rozhodnutí o skrytí či modifikaci obsahu.
3. **Sentiment Analysis & Tone Transformation (Style Transfer):**
   a. LLM proces přeměny senzacetivního textu na neutrální věcná fakta (změna tónu z panického na klidný).
4. **Sémantická deduplikace (Vector Embeddings & Cosine Similarity):**
   a. Slučování duplicitních zpráv napříč různými zpravodajskými weby do jednoho unifikovaného přehledu.
5. **Autonomní agentní logika (ReAct Framework):**
   a. Agent analyzuje typ stránky, vyhodnocuje uživatelské preference v nastavení a rozhoduje o rozsahu DOM mutace.

5. Architektura řešení

- **Frontend (Chrome Extension):**
  - *Popup UI:* Umožňuje uživateli zapínat/vypínat filtry pro danou doménu (např. přepínač „Skrýt obsah od nesledovaných“ pro Instagram, „Blokovat politiku“ pro zpravodajství).
  - *Content Script:* Provádí živou mutaci DOMu (skrývání elementů, přepisování titulků, vkládání AI shrnutí).
- **Backend (Python & FastAPI):**
  - Zpracovává textová data a strukturu stránek, řídí logiku LLM modelů, provádí klasifikaci témat a generuje instrukce pro úpravu DOMu.

6. Experimentální vyhodnotitelnost

- **Topic Filtering Accuracy:** Úspěšnost, s jakou AI správně zařadila a odfiltrovala zvolená citlivá témata (např. válka, politika) na testovacím vzorku článků.
- **Tone Neutralization Score (Sentiment Shift):** Kvantitativní ověření, že režim „Mírnější přístup“ prokazatelně snížil emoční náboj a negativitu textu.
- **DOM Mutation Latency:** Rychlost odezvy (v milisekundách) od detekce stránky po úspěšnou aplikaci filtrů v prohlížeči.
- **Compression Ratio:** Míra redukce nadbytečného objemu dat (díky shrnutím a skrytí irelevantních příspěvků).

7. Seznam všech metrik

- **Precision (Přesnost filtrace):** Kolik procent AI označených a skrytých článků (nebo nevhodného obsahu) bylo skutečně nežádoucích (minimalizace falešných poplachů).
- **Recall (Úplnost filtrace):** Kolik ze všech reálně nežádoucích článků / příspěvků v datasetu dokázala AI úspěšně odhalit a schovat.
- **F1-Score:** Harmonický průměr Precision a Recall pro celkové vyhodnocení úspěšnosti klasifikace témat (politika, válka atd.).
- **Sentiment Shift (Posun sentimentu):** Měření změny emočního náboje textu před a po zásahu – ověření, že text přešel od paniky/negativity k neutrálním faktům.
- **Toxicity Reduction Rate (%):** Procentuální pokles výskytu senzacetivních a toxických frází v textu po aktivaci mírnějšího přístupu.
- **Compression Ratio (Míra redukce objemu):** O kolik procent se zkrátil text (díky shrnutím a deduplikaci) při zachování klíčových informací.
- **Semantic Similarity (Zachování významu):** Porovnání sémantické blízkosti (vektorů) původního textu a AI shrnutí, aby se ověřilo, že zkratka nezkreslila fakta.

- **DOM Mutation Latency (Rychlost odezvy):** Čas v milisekundách od načtení stránky do chvíle, kdy prohlížeč reálně přepíše nebo skryje prvky.
- **Selector Success Rate (%):** Úspěšnost, s jakou rozšíření dokázalo na různých webech bezchybně najít správné HTML elementy.